

LSD-SLAM

🕒 Created	@October 4, 2023 6:27 PM
🏷️ Tags	

В основе **Large Scale Direct SLAM** лежит метод прямой визуальной одометрии (direct visual odometry), который оптимизирует геометрию напрямую на image intensities, что позволяет получить из изображения максимум информации, а не полагаться на ключевые точки или фичи.

Основные нововведения

Semi-dense depth filtering formulation - позволяет строить визуальную одометрию в режиме реального времени на CPU и смартфонах, но за счёт этого метода как такового мы только фиксируем движение камеры. [Статья, на которую ссылается автор](#)

Pose-graph optimization - мир представляется в виде кадров в вершинах графа, соединённых возможными изменениями позы (*мне кажется, это подразумевается под "pose-pose constraints"*). Граф оптимизируется при помощи библиотеки g2o

Авторы предлагают комбинировать:

1. **direct image alignment** coupled with filtering-based estimation of **semi-dense depth maps**
2. Граф с ключевыми кадрами в вершинах и рёбрами, обозначающими трехмерные изменения положения в пространстве.

А дальше идёт матан...

Условные обозначения:

1. R - латинские заглавные буквы - матрицы
2. ξ - малые буквы (*греческие?*) - векторы
3. $\Omega \subset \mathbb{R}^2$ - множество нормализованных пикселей изображения, то есть учитывающих сопутствующую калибровку камеры (*латеховская буква для вещественных чисел тут не отрисовывается, так что будет с бэкслэшэм, чтобы с матрицами не путать*)

4. $I : \Omega \rightarrow \mathbb{R}$ - изображение (надеюсь, дальше пояснят, в чём суть этого отображения) *Urpd: Пояснения не было*, так что просто предположу, что мы отображаем каждый пиксель в какое-то конкретное вещественное число по его значениям каналов цветов. Самое простое – перемножить $b * g * r$, но, наверное, нам будет достаточно использовать ЧБ изображение, что уменьшит наш разброс значений с 2^{32} до 2^8
5. $D : \Omega \rightarrow \mathbb{R}^+$ - per-pixel inverse depth map (попиксельное отображение обратной глубины)
6. $V : \Omega \rightarrow \mathbb{R}^+$ - inverse depth variance map (отображение дисперсии обратной глубины)
7. $d = z^{-1}$ - инверсия глубины точки z

Трансформация твёрдого тела (3D Rigid body transformation)

Описывается матрицей $G \in SE(3)$, которая включает вращение (R) и переход (t): Для оптимизации записи матрица отображается в вектор $\mathbb{R}^6 := SE(3)(G)$.

Переход от кадра i к кадру j описывается обозначается ij , далее вводится операция конкатенации векторов: $ij = ikkj = SE(3)(G_{ik}G_{kj}) = SE(3)((ik)(kj))$. Далее мы определяем функцию перехода для пикселя p за счёт вектора (честно, я не понимаю, что за магия тут творится (особенно справа, где мы, согласно нотации выше, умножаем матрицу 2×2 на вектор длины 4 и получаем вектор длины 4, но в результате мы добавляем... глубину в изображение?):

$$G = \begin{pmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0} & 1 \end{pmatrix} \quad \text{with} \quad \mathbf{R} \in SO(3) \text{ and } \mathbf{t} \in \mathbb{R}^3.$$

$$\omega(\mathbf{p}, d, \xi) := \begin{pmatrix} x'/z' \\ y'/z' \\ 1/z' \end{pmatrix} \quad \text{with} \quad \begin{pmatrix} x' \\ y' \\ z' \\ 1 \end{pmatrix} := \exp_{\mathfrak{se}(3)}(\xi) \begin{pmatrix} \mathbf{p}_x/d \\ \mathbf{p}_y/d \\ 1/d \\ 1 \end{pmatrix}.$$

Трёхмерное преобразование подобия (3D Similarity Transformations)

Здесь определяется матрица S , которая описывает вращение, масштабирование и смещение: Операции для вектора здесь описываются

аналогичным образом, что и для трансформации твёрдого тела, с той лишь разницей, что \mathbb{R}^7 (пространство $\text{SIM}(3)$)(откуда добавляется степень свободы несколько загадочно... Наверное (даже очень вероятно), логарифмирование матриц - операция совсем иного рода, нежели простое логарифмирование) Статья по этой теме

$$\mathbf{S} = \begin{pmatrix} s\mathbf{R} & \mathbf{t} \\ \mathbf{0} & 1 \end{pmatrix} \quad \text{with} \quad \mathbf{R} \in \text{SO}(3), \mathbf{t} \in \mathbb{R}^3 \quad \text{and} \quad s \in \mathbb{R}^+.$$

Weighted Gauss-Newton Optimization on Lie-Manifolds

(пожалуй, тут без перевода). Два изображения выравниваются при помощи метода Гаусса-Ньютона (что такое g , вообще не ебу, МАМА, МНЕ СТРАШНО): (Ладно, спокойно... Тут ведь чётко отмечено, что вся формула за суммой - это и есть $g^2(i)$). И вообще, осталось чуть матана... Вроде бы...) Далее подбирается такое \mathbf{p} , которое минимизирует ошибку. Сначала считается $\mathbf{J}(\mathbf{p})$ по описанным выше формулам. Затем считается left-multiplied increment $\Delta \mathbf{p}$ путём нахождения минимума для второго приближения Гаусса-Ньютона для E : Где, \mathbf{J} - производная сложенного остаточного вектора (stacked residual vector) $\mathbf{r} = (r_1, \dots, r_n)^T$ с учётом левоумноженного инкремента (left-multiplied increment) и $\mathbf{J}^T \mathbf{J}$ Gauss-Newton approximation of the Hessian of E . (метод Гаусса-Ньютона на Википедии) Далее мы получаем новую оценку через умножение с вычисленным инкрементом: $\mathbf{p}_{n+1} = \mathbf{p}_n + \Delta \mathbf{p}$ Для устойчивости к отображениям и другим искажениям было решено итеративно пересчитывать матрицу весов $\mathbf{W} = \mathbf{W}(\mathbf{p}_n)$, которая понижает вес самых больших остатков. Получили следующие формулы: В итоге мы получаем важную информацию о корреляциях между шумом в разных измерениях. Использовать это будет в оптимизации графа и, насколько я понял, в $g2o$ этот метод УЖЕ, МАТЬ ВАШУ, РЕАЛИЗОВАН!!! Зачем я прожил эти 2 часа жизни?.. Ладно, будем надеяться, что хотя бы первые пункты из математической аннотации не были записаны впустую...

$$E(\boldsymbol{\xi}) = \sum_i \underbrace{(I_{\text{ref}}(\mathbf{p}_i) - I(\omega(\mathbf{p}_i, D_{\text{ref}}(\mathbf{p}_i), \boldsymbol{\xi})))^2}_{=: r_i^2(\boldsymbol{\xi})},$$

$$\delta \xi^{(n)} = -(\mathbf{J}^T \mathbf{J})^{-1} \mathbf{J}^T \mathbf{r}(\xi^{(n)}) \quad \text{with} \quad \mathbf{J} = \left. \frac{\partial \mathbf{r}(\epsilon \circ \xi^{(n)})}{\partial \epsilon} \right|_{\epsilon=0},$$

$$E(\xi) = \sum_i w_i(\xi) r_i^2(\xi),$$

and the update is computed as

$$\delta \xi^{(n)} = -(\mathbf{J}^T \mathbf{W} \mathbf{J})^{-1} \mathbf{J}^T \mathbf{W} \mathbf{r}(\xi^{(n)}).$$

Распространение неопределённости (Propagation of Uncertainty)

Позволяет рассчитать неопределённость на выходе на основании степени неопределённости данных на входе:

Propagation of uncertainty is a statistical tool to derive the uncertainty of the output of a function $f(\mathbf{X})$, caused by uncertainty on its input \mathbf{X} . Assuming \mathbf{X} to be Gaussian distributed with covariance $\Sigma_{\mathbf{X}}$, the covariance of $f(\mathbf{X})$ can be approximated (using the Jacobian \mathbf{J}_f of f) by

$$\Sigma_f \approx \mathbf{J}_f \Sigma_{\mathbf{X}} \mathbf{J}_f^T. \quad (11)$$

Общее описание LSD-SLAM, но уже более подробно:

1. Получается новое изображение и рассчитывается его трансформация твёрдого тела на основании прошлого кадра
2. Через фильтр глубины (пункт b) и либо ключевой кадр обновляется, либо заменяется (если камера перешла слишком далеко)
3. Если ключевой кадр был заменён, делается вывод, что карта глубины нового кадра не изменится, а значит его можно внедрить в глобальную карту с использованием коррекции при помощи расчёта трёхмерного преобразования подобия. Расчёт проводится с ближайшими ключевыми кадрами, сохранёнными ранее + непосредственным предшественником.

Для инициализации алгоритма достаточно задать случайную карту глубины и большую дисперсию

Карта представлена графом позиций, где каждая вершина i содержит изображение $I_i: \mathbb{R}^3 \rightarrow \mathbb{R}$, его обратную карту глубины $D_i: \mathbb{R}^2 \rightarrow \mathbb{R}^3$ и дисперсию обратной глубины $V_i: \mathbb{R}^2 \rightarrow \mathbb{R}^3$, причём глубина и её дисперсия определены только для части пикселей: $D_i \cdot \Omega_i$. Рёбра содержат трехмерное преобразование подобия (3D Similarity Transformations) T_{ij} , а также матрицу ковариации Σ_{ij} (тут ещё и ковариации вылезли... Что они значат вообще?..)

1. Пункт (f.i) - получение нового изображения На основании данных прошлого кадра i и нового изображения j рассчитывается самая вероятная трансформация твёрдого тела T_{ji} при помощи минимизации variance-normalized photometric error Дисперсия остатков $2\sigma_p(p, j)$ считается при помощи распространения неопределенности (e.5) (каким оно тут боком оказалось, если для этой сигмы так вроде бы уже формула есть?..). Далее мы предполагаем (!?) Gause Image Intensity noise $2I$ Для минимизации используется итеративно перевзвешиваемый метод оптимизации Гаусса-Ньютона (e.iv)

$$E_p(\xi_{ji}) = \sum_{\mathbf{p} \in \Omega_{D_i}} \left\| \frac{r_p^2(\mathbf{p}, \xi_{ji})}{\sigma_{r_p(\mathbf{p}, \xi_{ji})}^2} \right\|_{\delta} \quad (12)$$

$$\text{with } r_p(\mathbf{p}, \xi_{ji}) := I_i(\mathbf{p}) - I_j(\omega(\mathbf{p}, D_i(\mathbf{p}), \xi_{ji})) \quad (13)$$

$$\sigma_{r_p(\mathbf{p}, \xi_{ji})}^2 := 2\sigma_I^2 + \left(\frac{\partial r_p(\mathbf{p}, \xi_{ji})}{\partial D_i(\mathbf{p})} \right)^2 V_i(\mathbf{p}) \quad (14)$$

$$\|r^2\|_{\delta} := \begin{cases} \frac{r^2}{2\delta} & \text{if } |r| \leq \delta \\ |r| - \frac{\delta}{2} & \text{otherwise.} \end{cases}$$

2. (f.ii) Расчёт карты глубины и работа с ключевыми кадрами. Смещение камеры рассчитывается по формуле $\text{dist}(ji) := T_{ji}W_{ji}$, где W - диагональная матрица весов (мы их высчитывали в (e.iv) или это вообще новые веса, подбираемые случайно?..) Если было принято решение заменить ключевой

кадр, по формулам из статьи пункта (b) вычисляем на основании карты глубину прошлого кадра карту нового. Если ключевой кадр не меняется, в текущем производится пересчёт карты глубины по формулам из статьи пункта (b)

3. Ограничения и прямое выравнивание изображений с учётом скейлинга.

- a. Если был выбран новый ключевой кадр, то зафиксированный сравнивается со своим предшественником и проводится минимизация ошибки для расчета трёхмерного преобразования подобия (в нём кроме фотометрической погрешности r_p считается также погрешность глубины r_d): Поиск минимального j_i проводится также методом Гаусса-Ньютона

$$E(\xi_{ji}) := \sum_{\mathbf{p} \in \Omega_{D_i}} \left\| \frac{r_p^2(\mathbf{p}, \xi_{ji})}{\sigma_{r_p}^2(\mathbf{p}, \xi_{ji})} + \frac{r_d^2(\mathbf{p}, \xi_{ji})}{\sigma_{r_d}^2(\mathbf{p}, \xi_{ji})} \right\|_\delta, \quad (17)$$

where the photometric residual r_p^2 and $\sigma_{r_p}^2$ is defined as in (13) - (14). The depth residual and its variance is computed as

$$r_d(\mathbf{p}, \xi_{ji}) := [\mathbf{p}']_3 - D_j([\mathbf{p}']_{1,2}) \quad (18)$$

$$\sigma_{r_d(\mathbf{p}, \xi_{ji})}^2 := V_j([\mathbf{p}']_{1,2}) \left(\frac{\partial r_d(\mathbf{p}, \xi_{ji})}{\partial D_j([\mathbf{p}']_{1,2})} \right)^2 + V_i(\mathbf{p}) \left(\frac{\partial r_d(\mathbf{p}, \xi_{ji})}{\partial D_i(\mathbf{p})} \right)^2, \quad (19)$$

where $\mathbf{p}' := \omega_s(\mathbf{p}, D_i(\mathbf{p}), \xi_{ji})$ denotes the transformed point. Note that the Hu-

- b. Далее, если был добавлен новый ключевой кадр K_i в карту, находим ближайшие к нему 10 ключевых кадров K_j, \dots, K_{j_n} , и при помощи алгоритма из этой статьи находим замыкания графа. Чтобы избежать ложных обнаружений, мы дополнительно проверяем разницу векторов между кадрами K_{jk} и K_i : Если разница достаточно мала, мы заключаем, что кадры K_{jk} и K_i образуют цикл и корректируем карту.

$$e(\xi_{j_k i}, \xi_{i j_k}) := (\xi_{j_k i} \circ \xi_{i j_k})^T \left(\Sigma_{j_k i} + \text{Adj}_{j_k i} \Sigma_{i j_k} \text{Adj}_{j_k i}^T \right)^{-1} (\xi_{j_k i} \circ \xi_{i j_k})$$

- c. Тут речь идёт об увеличении радиуса сближения для пространства $\text{SIM}(3)$, но, насколько я понял, эти увеличения совсем незначительны

4. Оптимизация карты проводится в фоновом режиме на всех кадрах (как я понял, W - каждый кадр, добавленный в итоговую карту) по классическому методу из (e.iv):

convention from Sec. 2.2 – defined by (W defining the world frame)

$$E(\xi_{W1} \dots \xi_{Wn}) := \sum_{(\xi_{ji}, \Sigma_{ji}) \in \mathcal{E}} (\xi_{ji} \circ \xi_{Wi}^{-1} \circ \xi_{Wj})^T \Sigma_{ji}^{-1} (\xi_{ji} \circ \xi_{Wi}^{-1} \circ \xi_{Wj}). \quad (21)$$

5. Итог... (Мама, роди меня обратно!) Общая концепция алгоритма ясна, а вот детали заставляют чувствовать невероятную боль. очень надеюсь, что описаны функции в статье были именно потому, что это статья, а в реализации мы сможем пользоваться библиотечными функциями. Опишу буквально в паре слов алгоритм ещё раз и прикрепляю схему: получаем кадр и считаем для него и текущего ключевого смещение твёрдого тела в $SE(3)$ пространстве, используя метод Гаусса-Ньютона; решаем на основании данных о смещении, нужно ли нам обновить данные текущего ключевого кадра или создать новый. Если создаём новый ключевой кадр, то прошлый добавляем в карту, посчитав для него смещение со скейлингом в $SIM(3)$. По полученным смещениям и параметрам самих изображений (карты глубины) пытаемся обнаружить замыкания. После всего этого производим оптимизацию карты на основании подсчитанных смещений

